

Report tecnico Valtellina

Gianluca Meni, Federico Combi

June 2026

Contents

1	Introduzione e motivazione della scelta dei dataset	3
1.1	Problema A - Regressione (Spanish Wine Quality Dataset) . . .	3
1.2	Problema B - Classificazione (Mice Protein Expression)	3
2	Analisi esplorativa (EDA) con visualizzazioni	5
2.1	EDA - Regressione	5
2.1.1	Descrizione del dataset	5
2.1.2	Analisi delle variabili	5
2.1.3	Analisi dei valori mancanti	6
2.1.4	Analisi statistica descrittiva	6
2.1.5	Distribuzione delle variabili categoriche	6
2.1.6	Analisi della correlazione	7
2.1.7	Correlazione tra variabili numeriche	7
2.1.8	Associazione tra variabili categoriche	7
2.1.9	Considerazioni generali	8
2.1.10	Analisi degli outlier	8
2.1.11	Ricerca di osservazioni duplicate	8
2.1.12	Correlazione con il target	8
2.2	EDA - Classificazione	10
2.2.1	Descrizione del dataset	10
2.2.2	Analisi delle variabili	11
2.2.3	Analisi dei valori mancanti	11
2.2.4	Analisi statistica descrittiva	12
2.2.5	Distribuzione delle variabili categoriche	12
2.2.6	Analisi della correlazione	13
2.2.7	Analisi degli outlier	14
2.2.8	Ricerca di osservazioni duplicate	14
2.2.9	Analisi Feature più rilevanti	15
2.2.10	Analisi delle Componenti Principali (PCA)	16

3	Pipeline di data cleaning e feature engineering	18
3.1	Regressione	18
3.1.1	Data Cleaning e trasformazioni (Power Query & Notebook Python)	18
3.1.2	Importazione del dataset	18
3.1.3	Definizione dei tipi di dato	18
3.1.4	Gestione delle variabili categoriche e soglia di frequenza	18
3.1.5	Rimozione di variabili non utilizzate	18
3.1.6	Imputazione dei valori mancanti	19
3.1.7	Output finale del preprocessing	19
3.2	Classificazione	19
3.2.1	Data Cleaning e trasformazioni (Power Query & Notebook python)	19
3.2.2	Importazione del dataset	19
3.2.3	Definizione dei tipi di dato	19
3.2.4	Rimozione di variabili non utilizzate	20
3.2.5	Codifica della variabile target	20
3.2.6	Imputazione dei valori mancanti	20
3.2.7	Output finale del preprocessing	21
4	Modelli sviluppati	22
4.1	Regressione	22
4.2	Classificazione	22
5	Analisi delle metriche e scelta del modello migliore	24
5.1	Regressione	24
5.2	Confronto delle prestazioni	24
5.3	Analisi dei risultati	24
5.3.1	Migliori iperparametri e analisi best model	25
5.4	Classificazione	27
5.4.1	Metriche di valutazione	27
5.4.2	Migliori iperparametri e analisi best model	28
6	Interpretazione dei risultati e conclusioni	32
6.1	Regressione	32
6.2	Classificazione	32
6.2.1	Considerazioni Metodologiche e Proposta di Analisi Aggiuntiva	32
7	Divisione del lavoro tra i membri del gruppo	34

1 Introduzione e motivazione della scelta dei dataset

In questa sezione vengono descritti i dataset utilizzati per i due problemi affrontati nel progetto, insieme alle motivazioni della loro scelta e alle principali ipotesi iniziali sui dati.

1.1 Problema A - Regressione (Spanish Wine Quality Dataset)

<https://www.kaggle.com/datasets/fedesoriano/spanish-wine-quality-dataset>

Il Problema A si colloca in un contesto di analisi dei dati enologici, con l'obiettivo di stimare il prezzo di una bottiglia di vino sulla base delle sue caratteristiche chimico-fisiche e qualitative. Questo tipo di problema è rilevante in ambito commerciale e industriale, in quanto permette di supportare strategie di pricing e valutazione del prodotto.

Il dataset scelto, *Spanish Wine Quality Dataset*, è particolarmente adatto a un task di regressione poiché include una variabile target continua (*price*) e un insieme di variabili numeriche e categoriche che descrivono le caratteristiche del vino. Questo rende possibile modellare relazioni non lineari tra le feature e il valore finale del prodotto.

Le variabili disponibili includono caratteristiche chimiche, informazioni qualitative e attributi descrittivi del vino, mentre la variabile target è il prezzo della bottiglia.

Si ipotizza che la distribuzione del prezzo non sia uniforme, ma caratterizzata da una possibile asimmetria e dalla presenza di valori estremi (outlier), tipici dei mercati reali.

Dal punto di vista della qualità del dato, si prevede la presenza di valori mancanti e possibili incongruenze tra variabili categoriche e numeriche, che richiederanno opportune fasi di pulizia e preprocessing.

1.2 Problema B - Classificazione (Mice Protein Expression)

<https://archive.ics.uci.edu/dataset/342/mice+protein+expression>

Il Problema B si inserisce in un contesto scientifico di tipo biomedico, finalizzato alla classificazione di campioni di topi sulla base dell'espressione proteica. Questo tipo di analisi è tipicamente utilizzato nella ricerca biologica e medica per identificare pattern associati a condizioni sperimentali diverse.

Il dataset *Mice Protein Expression* è adatto a un problema di classificazione in quanto la variabile target (*class*) rappresenta categorie discrete che descrivono il topo in base a *genotype*, *behavior* e *treatment*. Le variabili disponibili sono principalmente continue e rappresentano livelli di espressione proteica misurati in laboratorio.

Si ipotizza che le classi siano sostanzialmente bilanciate, poiché il dataset è composto da 38 topi di controllo e 34 topi trisomici (Down syndrome), con un numero comparabile di osservazioni per ciascun gruppo sperimentale. Tuttavia, la diversa numerosità iniziale tra i gruppi potrebbe introdurre lievi squilibri nella distribuzione finale dei campioni.

Dal punto di vista della qualità del dato, il dataset potrebbe contenere valori mancanti o misurazioni rumorose tipiche di dati sperimentali biologici, oltre a possibili correlazioni elevate tra alcune variabili.

2 Analisi esplorativa (EDA) con visualizzazioni

Prima di procedere con le fasi di preprocessing e di addestramento dei modelli di Machine Learning è stata effettuata un'analisi esplorativa dei dati (Exploratory Data Analysis, EDA). L'obiettivo di questa fase è comprendere la struttura del dataset, valutarne la qualità, individuare eventuali problematiche che potrebbero influenzare le prestazioni dei modelli e ottenere una prima descrizione statistica delle variabili.

L'analisi esplorativa rappresenta una fase fondamentale di qualsiasi progetto di Data Science, poiché consente di evidenziare la presenza di dati mancanti, osservazioni duplicate, outlier, correlazioni tra le variabili e possibili sbilanciamenti delle classi. Le informazioni ottenute durante questa fase permettono inoltre di definire le strategie di preprocessing più appropriate e di orientare la successiva scelta degli algoritmi di classificazione.

2.1 EDA - Regressione

2.1.1 Descrizione del dataset

Il dataset analizzato contiene 7.500 osservazioni e 11 variabili relative a vini spagnoli. Ogni riga rappresenta un vino e include informazioni su produttore, denominazione, caratteristiche qualitative e metriche di popolarità e prezzo.

Le variabili disponibili sono:

- **Categoriche:** winery, wine, year, country, region, type, body, acidity
- **Numeriche:** rating, num_reviews, price

Il dataset è interamente relativo alla Spagna (country = Espana per tutte le osservazioni), quindi non presenta variabilità geografica a livello di paese.

2.1.2 Analisi delle variabili

Le variabili si suddividono in:

- **Variabili categoriche:** winery, wine, year, country, region, type, body, acidity
- **Variabili numeriche:** rating, num_reviews, price

Le variabili *body* e *acidity* sono codificate come categoriche ordinali, pur essendo rappresentate da valori numerici interi con significato qualitativo.

La variabile *year* è di tipo object a causa della presenza di valori non numerici come "N.V." (non vintage). La variabile *country* è costante e quindi non informativa per analisi comparative.

2.1.3 Analisi dei valori mancanti

I valori mancanti risultano limitati:

- **year:** 2 valori mancanti (0,027%)
- Sono inoltre presenti valori non standard:
- “N.V.” (non vintage): 3,84% del dataset
 - valori impliciti mancanti:
 - type: 7,27%
 - body: 15,59%
 - acidity: 15,59%

2.1.4 Analisi statistica descrittiva

Le variabili numeriche mostrano le seguenti caratteristiche:

- **rating:** media 4,25, mediana 4,20, bassa variabilità ($\text{std} \approx 0,12$). I punteggi risultano concentrati su valori elevati.
- **num_reviews:** media 451, mediana 404, forte asimmetria positiva (max 32.624), con pochi vini estremamente recensiti.
- **price:** media 60,10, mediana 28,53, elevata dispersione ($\text{std} \approx 150,36$) e valori estremi fino a 3.119,08.

Nel complesso, le variabili quantitative presentano distribuzioni fortemente asimmetriche, in particolare prezzo e numero di recensioni.

2.1.5 Distribuzione delle variabili categoriche

Le variabili categoriche mostrano distribuzioni fortemente sbilanciate:

- **Winery:** il produttore più frequente (Contino) rappresenta circa il 6,09% del dataset.
- **Wine:** le categorie più comuni (Reserva, Gran Reserva) circa il 6% ciascuna.
- **Year:** il 2011 è l'anno più rappresentato (15,87%), seguito dal 2016 (11,96%).
- **Region:** Rioja (32,53%) e Ribera del Duero (18,84%).
- **Type:** Rioja Red (31,43%) e Ribera Del Duero Red (18,76%).
- **Body:** valore 4 predominante (54,93%).
- **Acidity:** livello 3 predominante (80,37%).

Nel complesso si osserva una forte concentrazione su poche classi dominanti.

2.1.6 Analisi della correlazione

L'analisi della correlazione è stata condotta sia sulle variabili numeriche, mediante coefficiente di Pearson, sia sulle variabili categoriche, utilizzando il coefficiente V di Cramér.

2.1.7 Correlazione tra variabili numeriche

La matrice di correlazione evidenzia i seguenti risultati:

- **rating e price:** correlazione positiva moderata ($r = 0.545$), suggerendo che i vini con prezzo più elevato tendono ad avere valutazioni leggermente superiori.
- **rating e num_reviews:** correlazione quasi nulla ($r = 0.015$), indicando che la popolarità in termini di numero di recensioni non è associata alla qualità percepita.
- **price e num_reviews:** correlazione trascurabile e leggermente negativa ($r = -0.030$), suggerendo indipendenza tra prezzo e popolarità.

Nel complesso, emerge una relazione significativa esclusivamente tra prezzo e rating, mentre le altre variabili numeriche risultano pressoché indipendenti.

2.1.8 Associazione tra variabili categoriche

L'analisi mediante V di Cramér evidenzia associazioni molto forti tra diverse variabili qualitative:

- **Relazioni quasi perfette:**
 - wine e type ($V = 0.990$)
 - wine e region ($V = 0.979$)
 - winery e wine ($V = 0.953$)
- **Relazioni molto forti tra caratteristiche del vino:**
 - winery con region, type, body e acidity ($V \approx 0.86 - 0.93$)
 - wine con body e acidity ($V \approx 0.90$)
 - type con body e acidity ($V \approx 0.88$)
- **Relazioni tra territorio e caratteristiche sensoriali:**
 - region con body ($V = 0.829$)
 - region con type ($V = 0.815$)

Nel complesso, le variabili categoriche risultano fortemente interdipendenti, con valori di V di Cramér generalmente elevati. Questo suggerisce una struttura altamente ridondante dell'informazione qualitativa, dove molte variabili descrivono aspetti strettamente collegati dello stesso fenomeno (vino, produttore, regione e tipologia).

2.1.9 Considerazioni generali

L'analisi congiunta evidenzia due risultati principali:

- Le variabili numeriche mostrano poche correlazioni significative, ad eccezione della relazione tra prezzo e rating.
- Le variabili categoriche sono invece fortemente correlate tra loro, indicando possibile multicollinearità informativa.

Questi risultati suggeriscono che una futura modellazione predittiva dovrebbe tenere conto della ridondanza tra variabili categoriche, eventualmente ricorrendo a tecniche di selezione delle feature o riduzione della dimensionalità.

2.1.10 Analisi degli outlier

Sono presenti outlier evidenti nelle variabili numeriche:

- **price:** valori fino a 3.119,08 rispetto a una mediana di 28,53
- **num_reviews:** massimo di 32.624 contro una mediana di 404

La variabile *rating* non mostra outlier significativi, risultando altamente concentrata.

Abbiamo deciso di mantenere gli outliers visto che il dataset rappresenta entità reali e quindi eliminandoli dal dataset smetterebbe di essere una rappresentazione realistica della situazione

2.1.11 Ricerca di osservazioni duplicate

Il dataset presenta un numero molto elevato di duplicati:

- 5.452 righe duplicate su 7.500 totali

Questo indica una forte ridondanza nei dati o la presenza di estrazioni multiple delle stesse osservazioni. Tale livello di duplicazione richiede attenzione, poiché può influenzare significativamente le analisi statistiche e i modelli predittivi, rendendo necessaria una fase di deduplicazione o una verifica della definizione di duplicato.

Nel nostro caso abbiamo deciso di eliminarli riducendo il dataset a 2048.

2.1.12 Correlazione con il target

L'analisi della correlazione rappresenta un passaggio fondamentale nella fase di esplorazione dei dati (EDA), in quanto ci permette di quantificare il legame lineare esistente tra le variabili indipendenti (le caratteristiche dei vini) e la variabile target.




Figure 1: Correlazione delle feature con il target.

Dall'analisi emerge come *winery* e *wine* siano le feature più correlate, per cui andiamo ad analizzare la distribuzione delle frequenze.




Figure 2: Distribuzione di wine.




Figure 3: Distribuzione di winery.

2.2 EDA - Classificazione

2.2.1 Descrizione del dataset

Il dataset utilizzato è costituito da **1080 osservazioni** e **82 variabili**. Ogni osservazione rappresenta un campione ottenuto da un topo sottoposto a differenti condizioni sperimentali, mentre le variabili descrivono principalmente i livelli di espressione di specifiche proteine coinvolte in diversi processi biologici.

Dal punto di vista dei tipi di dato, il dataset risulta composto quasi esclusivamente da variabili numeriche continue, memorizzate come valori in virgola mobile (`float64`). In particolare, sono presenti 77 variabili numeriche che rappresentano le misurazioni dell'espressione proteica. Oltre a queste, sono presenti cinque variabili categoriche utilizzate per identificare i campioni e descrivere le relative condizioni sperimentali.

Le variabili categoriche presenti nel dataset sono:

- **MouseID**: identificativo univoco del campione;
- **Genotype**: distingue i topi appartenenti al gruppo di controllo (*Control*) da quelli affetti dalla sindrome di Down (*Ts65Dn*);
- **Treatment**: identifica il trattamento farmacologico ricevuto, distinguendo tra *Memantine* e *Saline*;
- **Behavior**: indica il protocollo comportamentale sperimentale applicato (*C/S* oppure *S/C*);
- **class**: rappresenta la combinazione delle precedenti caratteristiche e costituisce la classe finale del campione.

La struttura del dataset risulta quindi particolarmente adatta all'applicazione di tecniche di classificazione supervisionata, in quanto combina un elevato numero di variabili descrittive con una variabile target costituita da differenti classi sperimentali.

2.2.2 Analisi delle variabili

La maggior parte delle feature descrive il livello di espressione di proteine coinvolte nei principali meccanismi di trasduzione del segnale neuronale, nella plasticità sinaptica e nei processi associati alla memoria e all'apprendimento. Tra queste sono presenti proteine appartenenti alle famiglie MAPK, AKT, mTOR, CREB, CAMKII e numerosi altri biomarcatori frequentemente utilizzati nello studio della sindrome di Down.

2.2.3 Analisi dei valori mancanti

Un aspetto particolarmente importante emerso durante l'analisi esplorativa riguarda la presenza di valori mancanti.

La maggior parte delle variabili presenta solamente tre valori mancanti, corrispondenti a circa lo 0.28% delle osservazioni. Tuttavia, alcune proteine mostrano percentuali sensibilmente più elevate, rendendo necessaria una valutazione accurata nella fase di preprocessing.

Le variabili maggiormente interessate dalla presenza di dati mancanti sono riportate nella Tabella 1.

Table 1: Variabili con la maggiore percentuale di valori mancanti.

Variabile	Valori mancanti (%)
BCL2_N	26.39
H3MeK4_N	25.00
BAD_N	19.72
EGR1_N	19.44
H3AcK18_N	16.67
pCFOS_N	6.94
ELK_N	1.67
Bcatenin_N	1.67

Come si osserva, soltanto un numero limitato di variabili presenta una percentuale significativa di dati mancanti, mentre la quasi totalità delle feature risulta pressoché completa.

La presenza di tali valori mancanti non compromette comunque la qualità complessiva del dataset, ma richiede l'adozione di opportune strategie di gestione nella successiva fase di preprocessing. In particolare, sarà necessario valutare tecniche di imputazione in grado di preservare il contenuto informativo delle variabili senza introdurre distorsioni nella distribuzione dei dati.

Nel complesso, il dataset presenta una buona qualità, poiché la maggior parte delle feature contiene un numero estremamente ridotto di osservazioni mancanti e nessuna variabile risulta completamente priva di informazioni.

2.2.4 Analisi statistica descrittiva

Per ottenere una prima caratterizzazione quantitativa del dataset sono state calcolate, per ciascuna variabile numerica, le principali statistiche descrittive: media, mediana, valore minimo, valore massimo e deviazione standard.

L'analisi evidenzia una notevole eterogeneità nelle scale di misura delle diverse proteine. Alcune variabili presentano valori medi inferiori a 0.2, mentre altre assumono valori medi superiori a 3.

Per molte variabili la media e la mediana risultano molto vicine, indicando distribuzioni relativamente simmetriche. In altri casi, invece, la presenza di differenze più marcate tra questi due indicatori suggerisce distribuzioni asimmetriche o influenzate da osservazioni estreme.

Anche la deviazione standard varia sensibilmente tra le diverse feature, evidenziando differenti livelli di variabilità biologica. Alcune proteine mostrano una dispersione molto contenuta, mentre altre presentano una maggiore variabilità tra i campioni analizzati.

Tra le variabili che evidenziano la maggiore variabilità si possono citare `NR2A_N`, `pCAMKII_N`, `ERK_N`, `pKCG_N` e `AcetylH3K9_N`, caratterizzate da intervalli di valori piuttosto ampi. Al contrario, proteine come `BAX_N`, `ARC_N`, `ERBB4_N` e `GFAP_N` presentano distribuzioni decisamente più concentrate.

Nel complesso, le statistiche descrittive confermano la presenza di una buona variabilità nei dati, caratteristica che rappresenta un elemento favorevole per l'addestramento di modelli predittivi.

2.2.5 Distribuzione delle variabili categoriche

Successivamente è stata analizzata la distribuzione delle variabili categoriche al fine di evidenziare eventuali squilibri tra le diverse classi. È importante sottolineare che tali distribuzioni non sono casuali, ma sono state definite a priori dal disegno sperimentale, e riflettono quindi la struttura prevista dell'esperimento.

La variabile `Genotype` risulta perfettamente bilanciata, con 570 campioni appartenenti al gruppo *Control* (52.78%) e 510 campioni appartenenti al gruppo *Ts65Dn* (47.22%).

Una distribuzione analoga si osserva per la variabile `Treatment`, che include 570 campioni trattati con Memantine e 510 campioni trattati con soluzione salina (Saline).

Anche la variabile `Behavior` mostra una ripartizione equilibrata tra i due protocolli sperimentali, con 555 osservazioni nella categoria *S/C* (51.39%) e 525 nella categoria *C/S* (48.61%).

Infine, la variabile target `class`, composta da otto categorie derivanti dalla combinazione di genotipo, trattamento e protocollo comportamentale, presenta anch'essa una distribuzione sostanzialmente bilanciata: la classe più rappresentata conta 150 osservazioni (13.89%), mentre quella meno frequente ne include 105 (9.72%).

2.2.6 Analisi della correlazione

Per approfondire le relazioni esistenti tra le variabili numeriche è stata calcolata la matrice di correlazione utilizzando il coefficiente di Pearson. Tale coefficiente misura l'intensità della relazione lineare tra due variabili assumendo valori compresi tra -1 e 1 : valori prossimi a 1 indicano una forte correlazione positiva, valori prossimi a -1 una forte correlazione negativa e valori vicini a 0 indicano una correlazione lineare trascurabile.

Le correlazioni più significative sono riportate nella Tabella 2.

Table 2: Principali correlazioni positive tra le variabili numeriche.

Variabile 1	Variabile 2	Correlazione
ARC_N	pS6_N	1.0000
DYRK1A_N	BRAF_N	0.9596
DYRK1A_N	ITSN1_N	0.9595
NR1_N	pNR1_N	0.9479
DYRK1A_N	pERK_N	0.9457
pERK_N	BRAF_N	0.9270
ITSN1_N	BRAF_N	0.9176
NR1_N	Bcatenin_N	0.9146
pNR1_N	pNR2B_N	0.9065
ITSN1_N	pERK_N	0.9063
NR1_N	pNR2B_N	0.8951
NR1_N	NR2A_N	0.8739
pAKT_N	pMEK_N	0.8731
pNR1_N	Bcatenin_N	0.8726
NR2A_N	pNR1_N	0.8697
NR2A_N	Bcatenin_N	0.8667
NR2A_N	pNR2B_N	0.8599
AMPKA_N	TIAM1_N	0.8578
NR1_N	TRKA_N	0.8569
ELK_N	ERK_N	0.8561

Tra i risultati più interessanti emerge una correlazione perfetta ($r = 1.000$) tra **ARC_N** e **pS6_N**, suggerendo che le due variabili assumono valori identici o praticamente coincidenti all'interno del dataset. Sono inoltre presenti numerose correlazioni superiori a 0.90 , tra cui quelle tra **DYRK1A_N** e **BRAF_N**, tra **DYRK1A_N** e **ITSN1_N**, tra **NR1_N** e **pNR1_N**, nonché tra **pERK_N** e **BRAF_N**. Anche molte altre coppie di proteine presentano coefficienti compresi tra 0.80 e 0.90 , confermando l'esistenza di gruppi di feature fortemente associate.

La presenza di queste correlazioni suggerisce una certa ridondanza informativa tra alcune variabili, fenomeno piuttosto comune nei dataset biologici. Tale aspetto è stato tenuto in considerazione nelle successive fasi di preprocessing e modellazione, poiché la multicollinearità può influenzare il comportamento di alcuni algoritmi di classificazione e rendere vantaggiosa l'applicazione di tecniche

di selezione delle feature o di riduzione della dimensionalità.

2.2.7 Analisi degli outlier

Un'ulteriore fase dell'analisi esplorativa ha riguardato l'identificazione di eventuali valori anomali (*outlier*) all'interno delle variabili numeriche. Gli outlier rappresentano osservazioni che si discostano in maniera significativa dalla distribuzione generale dei dati e che, in alcuni casi, possono influenzare il comportamento degli algoritmi di Machine Learning.

L'individuazione degli outlier è stata effettuata utilizzando il metodo basato sull'Interquartile Range (IQR), considerando come anomale tutte le osservazioni inferiori a

$$Q_1 - 1.5 \times IQR$$

oppure superiori a

$$Q_3 + 1.5 \times IQR,$$

dove Q_1 e Q_3 rappresentano rispettivamente il primo e il terzo quartile della distribuzione.

L'analisi ha evidenziato la presenza di outlier in diverse variabili del dataset. Tuttavia, la loro incidenza risulta complessivamente contenuta: anche la feature caratterizzata dal numero più elevato di osservazioni anomale presenta una percentuale pari a circa il **7.04%** del totale dei campioni.

Considerata la natura biologica del dataset, tali osservazioni non sono state interpretate come errori di misurazione, bensì come possibili manifestazioni della naturale variabilità biologica tra i soggetti analizzati. La rimozione degli outlier avrebbe infatti comportato una perdita di informazioni potenzialmente rilevanti e avrebbe potuto alterare la distribuzione originale dei dati.

Per tali motivi si è scelto di mantenere tutti gli outlier individuati, senza applicare procedure di eliminazione o trasformazione. Questa decisione consente di preservare la variabilità biologica presente nel dataset e di sviluppare modelli maggiormente rappresentativi delle condizioni sperimentali reali.

2.2.8 Ricerca di osservazioni duplicate

Un ulteriore controllo è stato effettuato per verificare l'eventuale presenza di osservazioni duplicate.

L'analisi ha evidenziato che il dataset non contiene righe duplicate: tutte le 1080 osservazioni risultano infatti univoche. Questo rappresenta un importante indicatore della qualità del dataset, poiché evita la presenza di informazioni ridondanti che potrebbero introdurre bias durante la fase di addestramento dei modelli di classificazione.

L'assenza di duplicati ha quindi reso non necessaria alcuna operazione di pulizia aggiuntiva sotto questo aspetto.

2.2.9 Analisi Feature più rilevanti

L'ultima fase di EDA si sposta sull'analisi delle feature più rilevanti, che hanno una correlazione elevata con il target.




Figure 4: Feature con correlazione più elevata con il target.

Per queste feature, è stata eseguita una analisi delle distribuzioni, da cui emerge una distribuzione non normale, con elevata skewness.




Figure 5: Distribuzione delle feature più correlate.

Per ultimo, si analizza visivamente per queste feature anche la presenza di outliers, anche se già effettuata in modo statistico precedentemente.




Figure 6: Boxplot delle feature più correlate.

2.2.10 Analisi delle Componenti Principali (PCA)

Andando oltre l'aspetto di EDA classica, l'elevato numero di proteine presenti nel dataset mice rende difficile una visualizzazione immediata delle relazioni tra i campioni. Per superare questo limite, abbiamo applicato la PCA (Principal Component Analysis) al fine di ridurre la dimensionalità dello spazio delle caratteristiche.

Il grafico seguente proietta i dati in uno spazio bidimensionale, permettendoci di osservare la distribuzione naturale delle classi.




Figure 7: Grafico della PCA in 2 dimensioni.

Nonostante la riduzione a sole due dimensioni comporti inevitabilmente una perdita di informazioni, il grafico evidenzia una chiara tendenza dei dati a organizzarsi in regioni specifiche. Sebbene vi sia una sovrapposizione parziale tra alcuni gruppi, si osserva che le diverse classi non sono distribuite in modo del tutto casuale, ma tendono a formare dei cluster distinti nello spazio proiettato.

3 Pipeline di data cleaning e feature engineering

3.1 Regressione

3.1.1 Data Cleaning e trasformazioni (Power Query & Notebook Python)

Il processo di pulizia e trasformazione dei dati è stato articolato in due fasi successive: una prima fase di preprocessing realizzata tramite Power Query e una seconda fase di imputazione dei valori mancanti effettuata all'interno di un notebook Python.

3.1.2 Importazione del dataset

In una prima fase, il dataset è stato importato da un Lakehouse e si è proceduto alla navigazione fino alla tabella denominata *wines_spa*. Questo passaggio ha permesso di accedere alla base dati su cui svolgere tutte le successive operazioni di trasformazione.

3.1.3 Definizione dei tipi di dato

Successivamente, è stata effettuata una fase di pulizia preliminare dei dati, durante la quale i valori mancanti rappresentati come “NA” sono stati sostituiti con valori nulli. In parallelo, sono stati uniformati i tipi di dato delle variabili numeriche, così da garantire la corretta interpretazione dei campi quantitativi e ridurre la presenza di errori nelle successive elaborazioni. Le variabili interessate includono caratteristiche come acidità, corpo, rating e prezzo, per le quali è stata effettuata una gestione degli eventuali errori di conversione tramite procedure di controllo.

3.1.4 Gestione delle variabili categoriche e soglia di frequenza

Per evitare un'eccessiva dimensionalità in seguito all'encoding delle variabili categoriche, è stata introdotta una soglia di frequenza (threshold). In particolare, tutte le categorie che comparivano nel dataset con una frequenza inferiore alla soglia stabilita sono state accorpate in una classe unica denominata *other*. Questa scelta ha permesso di ridurre il numero complessivo di colonne generate durante la fase di encoding e di migliorare la stabilità dei modelli successivi.

3.1.5 Rimozione di variabili non utilizzate

Nella fase successiva, sono state eliminate le colonne ritenute non rilevanti per le analisi successive, ovvero il paese di origine e il nome del vino. Le variabili rimanenti sono state quindi riordinate al fine di migliorare la leggibilità e la coerenza strutturale del dataset.

3.1.6 Imputazione dei valori mancanti

L'imputazione dei valori mancanti è stata eseguita in una fase successiva all'interno di un notebook Python, adottando differenti strategie a seconda della natura delle variabili. In particolare, per le variabili numeriche *acidity*, *body*, e *year* è stata utilizzata la mediana, con l'obiettivo di ridurre l'influenza degli outlier e preservare la robustezza delle stime. Per la variabile *rating* è stata invece utilizzata la media, mentre per le variabili categoriche *type*, *winery* e *region* è stata applicata la moda, così da mantenere la coerenza con i valori più frequenti del dataset.

3.1.7 Output finale del preprocessing

Al termine del processo, il dataset risulta pulito, trasformato e strutturato in modo coerente. La base dati ottenuta è quindi pronta per le successive fasi di analisi esplorativa e modellazione predittiva.

3.2 Classificazione

3.2.1 Data Cleaning e trasformazioni (Power Query & Notebook python)

Il processo di data cleaning è stato implementato tramite Power Query, seguendo una pipeline strutturata che comprende importazione del dataset, trasformazione dei dati, gestione dei valori mancanti e codifica delle variabili categoriche. Parallelamente, nel notebook è stata effettuata l'imputazione dei valori mancanti dopo lo split del dataset, al fine di evitare fenomeni di data leakage.

3.2.2 Importazione del dataset

Il dataset è stato importato a partire da un file Excel archiviato all'interno di un Lakehouse. La procedura di accesso ha previsto la navigazione progressiva nella struttura del repository fino all'estrazione del foglio *Hoja1*, successivamente promosso a tabella con intestazioni corrette.

In particolare, le operazioni eseguite sono state:

- Accesso al Lakehouse e selezione del workspace di riferimento
- Navigazione nella directory *Files*
- Individuazione e apertura del file *Data_Cortex_Nuclear.xlsx*
- Lettura del foglio Excel *Hoja1* e promozione della prima riga a intestazione

3.2.3 Definizione dei tipi di dato

Una fase fondamentale del preprocessing ha riguardato la definizione esplicita dei tipi di dato, al fine di garantire coerenza nelle successive operazioni di analisi.

In particolare:

- Le variabili identificative e categoriche (*MouseID*, *Genotype*, *Treatment*, *Behavior*, *class*) sono state impostate come *text*
- Le variabili biologiche, corrispondenti a proteine e marker molecolari, sono state convertite in formato *numeric*

Questa standardizzazione consente una corretta gestione delle operazioni statistiche e riduce il rischio di interpretazioni errate dei dati.

3.2.4 Rimozione di variabili non utilizzate

Le variabili *Genotype*, *Treatment* e *Behavior* sono state successivamente rimosse dal dataset, in quanto non rilevanti per le analisi successive. Tale operazione ha permesso di ridurre la dimensionalità del dataset e semplificare le fasi di modellazione.

3.2.5 Codifica della variabile target

La variabile categorica target *class* è stata trasformata in una variabile numerica mediante encoding manuale, assegnando un identificativo intero a ciascuna classe sperimentale:

- c-CS-m $\rightarrow$ 0
- c-CS-s $\rightarrow$ 1
- c-SC-m $\rightarrow$ 2
- c-SC-s $\rightarrow$ 3
- t-CS-m $\rightarrow$ 4
- t-CS-s $\rightarrow$ 5
- t-SC-m $\rightarrow$ 6
- t-SC-s $\rightarrow$ 7

Questa trasformazione rende la variabile target utilizzabile all'interno di modelli di machine learning supervisionato.

3.2.6 Imputazione dei valori mancanti

L'imputazione dei valori mancanti è stata effettuata successivamente allo split del dataset in training e test set, al fine di evitare data leakage.

Poiché i valori mancanti erano esclusivamente di tipo numerico, è stata adottata la mediana come strategia di imputazione, garantendo robustezza rispetto alla presenza di eventuali outlier.

3.2.7 Output finale del preprocessing

Il dataset finale è stato ottenuto dopo la rimozione delle variabili non necessarie (*MouseID*, *class*, *MouseGroup*), successivamente alla generazione delle feature derivate e all'encoding della variabile target.

Il risultato è un dataset interamente numerico (ad eccezione della variabile target codificata), pronto per le successive fasi di analisi statistica e modellazione predittiva.

4 Modelli sviluppati

4.1 Regressione

In questo lavoro sono stati sviluppati diversi modelli di regressione al fine di confrontarne le prestazioni nella previsione della variabile target continua.

Regressione lineare

Come modello baseline è stata utilizzata una regressione lineare, scelta per la sua semplicità e interpretabilità. Questo modello assume una relazione lineare tra variabili indipendenti e variabile target e rappresenta un punto di riferimento per valutare il guadagno ottenuto con modelli più complessi.

Rete neurale

È stata implementata una rete neurale come modello non lineare principale. L'architettura è composta da due layer fully connected nascosti, progettati per catturare relazioni non lineari tra le variabili. La funzione di attivazione utilizzata nei layer intermedi introduce non linearità nel modello, mentre l'output layer è adatto alla regressione.

Per migliorare le prestazioni del modello è stata effettuata una **grid search** sugli iperparametri principali, tra cui numero di neuroni per layer, learning rate e batch size, al fine di individuare la configurazione ottimale.

XGBoost

Il modello XGBoost è stato utilizzato per sfruttare le sue capacità di boosting su alberi decisionali, risultando particolarmente efficace nel gestire interazioni non lineari tra le variabili. Sono stati ottimizzati i principali iperparametri per migliorarne le performance.

Ridge regression

Infine, è stata utilizzata una regressione Ridge, ovvero una regressione lineare regolarizzata con penalizzazione L2. Questo modello consente di controllare la complessità della soluzione e ridurre il rischio di overfitting, risultando particolarmente utile in presenza di multicollinearità tra le variabili.

4.2 Classificazione

Per il problema di classificazione sono stati sviluppati diversi modelli al fine di valutare la capacità di discriminare correttamente le classi della variabile target.

Regressione logistica

Come modello baseline è stata utilizzata la regressione logistica, che rappresenta l'equivalente classificatorio della regressione lineare. Questo modello fornisce una funzione decisionale lineare e permette di ottenere un riferimento interpretabile per il confronto con modelli più complessi.

Rete neurale

È stata implementata una rete neurale per la classificazione con architettura composta da due layer fully connected nascosti. L'ultimo layer utilizza una funzione di attivazione sigmoid o softmax in base al numero di classi.

Anche in questo caso è stata effettuata una **grid search** sugli iperparametri principali, tra cui numero di neuroni, learning rate e batch size, al fine di ottimizzare le prestazioni del modello.

XGBoost

Il modello XGBoost è stato impiegato come classificatore basato su boosting di alberi decisionali, risultando efficace nella gestione di relazioni non lineari tra le feature e la variabile target.

XGBoost con PCA

Nel problema di classificazione è stata inoltre testata una variante del modello XGBoost in combinazione con PCA, con l'obiettivo di ridurre la dimensionalità dei dati e valutare l'impatto della compressione informativa sulle prestazioni del classificatore. Questa configurazione non è stata invece adottata nel caso di regressione.

5 Analisi delle metriche e scelta del modello migliore

5.1 Regressione

Le metriche utilizzate per valutare i modelli di regressione sono:

- **MAE (Mean Absolute Error)**: misura l'errore medio assoluto tra valori predetti e valori reali, fornendo un'indicazione diretta dell'errore medio in unità del target.
- **MSE (Mean Squared Error)**: rappresenta la media degli errori quadratici e penalizza maggiormente gli errori più grandi, risultando sensibile agli outlier.
- **RMSE (Root Mean Squared Error)**: radice quadrata del MSE, consente un'interpretazione dell'errore nella stessa unità della variabile target.
- R^2 : coefficiente di determinazione che misura la capacità del modello di spiegare la variabilità dei dati. Valori più vicini a 1 indicano migliori prestazioni.
- **Adjusted R^2** : versione corretta dell' R^2 che penalizza l'aggiunta di variabili non informative, utile per confrontare modelli con diversa complessità.

5.2 Confronto delle prestazioni

Modello	MAE	RMSE	R2	Adj R2
Linear Regression	72.83	206.30	0.2307	0.2148
Ridge Regression	72.53	205.39	0.2374	0.2216
XGBoost Base	61.48	145.59	0.6168	0.6089
XGBoost Optimized	56.90	135.66	0.6673	0.6604
Neural Network Base	65.90	199.44	0.2810	0.1471
Neural Network Optimized	63.72	172.72	0.4607	0.3603

Table 3: Confronto delle prestazioni dei modelli di regressione sul test set.

5.3 Analisi dei risultati

I modelli lineari (Linear Regression e Ridge Regression) mostrano prestazioni limitate, con un valore di R^2 prossimo a 0.23. L'introduzione della regolarizzazione L2 non comporta miglioramenti significativi, indicando che il limite principale del modello non è legato all'overfitting, ma alla presenza di relazioni non lineari nei dati.

I modelli basati su gradient boosting (XGBoost) ottengono performance significativamente superiori, con un R^2 pari a 0.62 nel modello base e 0.67

dopo ottimizzazione degli iperparametri. Tuttavia, si osserva una differenza tra prestazioni in training e test, indicando una iniziale presenza di overfitting, successivamente ridotta tramite tuning.

Le reti neurali mostrano prestazioni inferiori rispetto a XGBoost nella configurazione base, con un forte gap tra training e test che evidenzia overfitting. L'introduzione di regolarizzazione migliora la stabilità del modello, riducendo il gap tra training e test, ma senza raggiungere le prestazioni dei modelli basati su boosting.

5.3.1 Migliori iperparametri e analisi best model

XGBoost:

- `learning_rate` = 0.05
- `max_depth` = 3
- `n_estimators` = 300

Neural Network:

- `neurons` = 64
- `dropout` = 0.0
- `learning_rate` = 0.001
- `batch_size` = 32
- `epochs` = 50
- `optimizer` = Adam




Figure 8: Residuals del modello XGBoost.

Il grafico dei residui visualizzato permette di valutare la precisione delle previsioni del nostro modello. Ecco una spiegazione dei punti chiave:

- **La Linea di Riferimento:** La linea rossa tratteggiata rappresenta l'errore nullo, ovvero il punto in cui il valore predetto dal modello coincide esattamente con il valore reale ($residuo = 0$). Idealmente, i punti dovrebbero distribuirsi in modo uniforme attorno a questa linea.
- **Eteroschedasticità (Variabilità dell'errore):** Si osserva chiaramente che i punti non sono distribuiti in modo uniforme. Per valori predetti bassi, i residui sono concentrati vicino allo zero, indicando che il modello è preciso. Tuttavia, all'aumentare del valore predetto, la dispersione dei residui cresce significativamente. In termini tecnici, il modello mostra *eteroschedasticità*: la sua incertezza aumenta per i vini di fascia alta.
- **Presenza di Outlier:** Alcuni punti si trovano molto lontano dalla linea rossa (con residui superiori a 750 o inferiori a -750). Questi rappresentano vini per i quali il modello ha commesso errori di stima molto grandi, suggerendo che esistano casi particolari che il modello fatica a interpretare correttamente.




Figure 9: Feature Importance del modello XGBoost.

Il grafico soprastante mostra quali caratteristiche hanno avuto il maggiore impatto nel determinare le previsioni del modello XGBoost. Ecco i punti fondamentali:

- **Dominio del Produttore:** La variabile più influente è `cat__winery_Other`, seguita da altri nomi di cantine specifiche come `cat__winery_Vega Sicilia`. Questo indica che il marchio del produttore è il fattore determinante principale per la stima del modello.
- **Importanza delle Valutazioni:** Oltre alla cantina, la variabile `num_mean_rating` occupa una posizione di rilievo. Ciò dimostra che la qualità percepita è un indicatore chiave utilizzato dal modello per correggere o raffinare la sua previsione.

Il modello si basa fortemente sull'identità del produttore e sulla reputazione del vino (rating) per effettuare le sue previsioni.

5.4 Classificazione

Confronto delle prestazioni dei modelli sul test set.

5.4.1 Metriche di valutazione

Le metriche utilizzate per valutare i modelli di classificazione sono le seguenti:

- **Accuracy:** misura la percentuale di predizioni corrette rispetto al totale delle osservazioni. Fornisce una valutazione generale delle prestazioni del modello.

- **Precision:** indica la proporzione di predizioni positive corrette rispetto a tutte le predizioni positive effettuate. Permette di valutare l'affidabilità delle predizioni positive.
- **Recall:** misura la capacità del modello di identificare correttamente tutti i casi positivi reali. È utile per valutare la completezza delle predizioni.
- **F1-score:** media armonica tra precision e recall, utilizzata per bilanciare entrambe le metriche in un unico indicatore.
- **AUC-ROC:** rappresenta la capacità del modello di distinguere tra classi positive e negative indipendentemente dalla soglia di decisione. Valori prossimi a 1 indicano una separazione quasi perfetta tra le classi.

Modello	Accuracy	Precision	Recall	F1-score	AUC-ROC
Regressione Logistica (Best)	0.9815	0.9823	0.9815	0.9817	0.9987
XGBoost Base	0.9861	0.9866	0.9861	0.9860	0.9999
XGBoost con PCA	0.9861	0.9864	0.9861	0.9862	0.9997
XGBoost Ottimizzato (PCA)	0.9861	0.9863	0.9861	0.9861	0.9994
Rete Neurale	0.9907	0.9911	0.9907	0.9907	0.9992

Table 4: Confronto delle prestazioni dei modelli sul test set.

Dalla tabella emergono ottimi risultati per tutti i modelli, e valutiamo il modello migliore tramite una cross-validation con diversi fold per verificare la robustezza del modello.

Metrica	Valore
Accuratezza media	0.9942
Deviazione standard	0.0037

Table 5: Risultati della cross-validation a 5 fold sul modello migliore.

5.4.2 Migliori iperparametri e analisi best model

Regressione Logistica (Grid Search):

- $C = 1$
- PCA con varianza spiegata pari a 0.99

XGBoost (Base ottimizzato):

- learning_rate = 0.1
- max_depth = 3
- n_estimators = 500

XGBoost (con PCA ottimizzato):

- learning_rate = 0.05
- max_depth = 3
- n_estimators = 300




Figure 10: Matrice di Confusione della NN.

Osservando la matrice di confusione, emerge un quadro estremamente positivo: il modello ha appreso in modo quasi perfetto le caratteristiche distintive delle diverse classi. La matrice mostra una diagonale principale quasi del tutto priva di dispersioni, a testimonianza di una precisione che rasenta la perfezione. Gli unici due errori riscontrati, uno scambio tra la classe 0 e la 4, e uno tra la classe 2 e la 6, rappresentano delle anomalie trascurabili rispetto alla mole complessiva di predizioni corrette, confermando la solidità dell'architettura scelta.




Figure 11: ROC curve della NN.

La validità del modello è ulteriormente supportata dalla curva ROC, dove osserviamo un valore di AUC pari a 1.00 per ogni singola classe. Questo indicatore suggerisce che la rete neurale non ha avuto alcuna difficoltà a separare le classi tra loro, mantenendo un tasso di veri positivi massimo a fronte di un tasso di falsi positivi nullo. Sebbene un risultato così netto sia eccellente, in alcuni casi potrebbe indicare un modello che ha imparato le caratteristiche del set di test in modo così specifico da sollevare il dubbio di un leggero overfitting, pur restando, nel caso specifico, una prova di grande efficacia del sistema.




Figure 12: Feature Importance della NN.

Infine, la feature importance ci aiuta a comprendere il motivo che sta dietro le decisioni della rete. Si nota infatti come il modello non assegni la fiducia in modo uniforme, ma privilegi nettamente alcune variabili biologiche. In particolare, **APP_N**, **ITSN1_N** e **BRAF_N** emergono come i pilastri informativi che guidano il processo decisionale.

6 Interpretazione dei risultati e conclusioni

6.1 Regressione

Nel complesso, XGBoost rappresenta il modello più efficace per il problema di regressione, ottenendo il miglior compromesso tra capacità predittiva e generalizzazione sui dati di test. Il modello è in grado di catturare relazioni non lineari e interazioni complesse tra le variabili, risultando significativamente superiore rispetto agli approcci lineari.

I modelli di regressione lineare e Ridge mostrano prestazioni sensibilmente inferiori, evidenziando come la relazione tra variabili esplicative e variabile target non possa essere adeguatamente descritta da una struttura puramente lineare, anche in presenza di regolarizzazione.

Le reti neurali, pur essendo teoricamente più flessibili e capaci di modellare relazioni non lineari, non riescono a superare le performance di XGBoost nel contesto analizzato. Questo risultato suggerisce che la complessità aggiuntiva del modello non è pienamente giustificata dalla struttura del dataset e che tecniche di boosting risultano più efficienti e robuste per questo tipo di problema.

6.2 Classificazione

I risultati ottenuti mostrano prestazioni molto elevate per tutti i modelli testati, con accuratezza sempre superiore al 98%. Questo suggerisce che il dataset è altamente strutturato e quasi linearmente separabile nello spazio delle variabili.

La Regressione Logistica ottiene risultati sorprendentemente competitivi rispetto ai modelli più complessi, indicando la presenza di relazioni prevalentemente lineari tra le variabili e la variabile target.

XGBoost mantiene prestazioni molto elevate in tutte le configurazioni. Tuttavia, l'applicazione della PCA non migliora i risultati, come previsto, poiché i modelli ad alberi non sono sensibili alla multicollinearità e non beneficiano della riduzione dimensionale.

La Rete Neurale rappresenta il modello con le migliori prestazioni complessive, anche se il miglioramento rispetto a XGBoost è marginale. Questo indica che la complessità aggiuntiva del modello non è strettamente necessaria per questo problema.

Alla luce dei risultati ottenuti, XGBoost rappresenta il miglior compromesso tra prestazioni, robustezza e complessità computazionale. La Rete Neurale, pur essendo leggermente superiore in termini di accuratezza, non offre un miglioramento significativo tale da giustificare la maggiore complessità operativa.

6.2.1 Considerazioni Metodologiche e Proposta di Analisi Aggiuntiva

L'analisi è stata condotta seguendo la procedura standard suggerita dalla documentazione ufficiale del dataset, la quale definisce ogni riga come un'osservazione indipendente. Pertanto, l'approccio adottato rappresenta la prassi metodologica convenzionale per questo tipo di esperimento.

Tuttavia, i risultati ottenuti sollevano un interrogativo critico: è possibile che il modello stia soffrendo di *data leakage*. È ipotizzabile, infatti, che il sistema stia imparando a riconoscere le specifiche caratteristiche del singolo topo anziché estrarre pattern biologici generalizzabili, a causa della forte correlazione intrinseca tra i campioni appartenenti allo stesso soggetto.

Come approfondimento metodologico, sarebbe possibile superare lo split casuale classico a favore di uno *split a gruppi*. Questa analisi aggiuntiva permetterebbe di isolare le osservazioni in base al topo di provenienza, garantendo che i dati di un singolo soggetto siano confinati interamente nel set di addestramento o in quello di test.

Tale approccio richiede l'integrazione di una conoscenza a priori sulla struttura dei dati:

- **Gestione della struttura:** Poiché il dataset è organizzato in blocchi di 15 elementi per ogni singolo individuo, è necessario mappare esplicitamente questa relazione (*group ID*).
- **Manipolazione dei dati:** Il dataset dovrebbe essere manipolato per trattare questi gruppi come unità indivisibili durante la fase di suddivisione.

In conclusione, mentre il procedimento standard qui svolto garantisce coerenza con le indicazioni della sorgente, una futura validazione *group-based* rappresenterebbe il test definitivo per verificare la robustezza del modello e la sua capacità di generalizzare su soggetti realmente nuovi.

7 Divisione del lavoro tra i membri del gruppo

- **Federico Combi:** esplorazione del dataset, analisi esplorativa dei dati (EDA), pulizia e pre-elaborazione del dataset, realizzazione del report in Power BI.
- **Gianluca Meni:** sviluppo e addestramento dei modelli di machine learning, valutazione delle prestazioni tramite metriche di classificazione e ottimizzazione degli iperparametri.