

REPORT TECNICO · JUNE 2026

Valtellina

Machine Learning Analysis



Regressione

Prezzo del vino spagnolo



Classificazione

Espressione proteica nei topi

Gianluca Meni & Federico Combi

Struttura del Progetto

Entrambi i progetti seguono un approccio strutturato in due fasi principali: l'Analisi Esplorativa dei Dati (EDA) e la fase di Machine Learning (ML), ciascuno adattato agli obiettivi specifici del dataset.

Vino Spagnolo: Previsione del Prezzo

Identificazione delle caratteristiche chiave del vino e delle correlazioni con il prezzo.

Cleaning del dataset in preparazione ai modelli di machine learning

Applicazione di algoritmi di regressione per prevedere il prezzo del vino in base alle sue proprietà.


Espressione Proteica nei Topi: Classificazione

Analisi delle distribuzioni proteiche e identificazione di pattern rilevanti.

Cleaning del dataset in preparazione ai modelli di machine learning

Utilizzo di algoritmi di classificazione per categorizzare l'espressione proteica e rilevare anomalie.

Pipeline di Data Cleaning



Il preprocessing è stato implementato in **Power Query** (pulizia, tipi di dato, soglia di frequenza per categorie rare) e in un **notebook Python** (imputazione dei valori mancanti dopo lo split per evitare data leakage).

Regressione — Spanish Wine Quality Dataset



Obiettivo

Stimare il **prezzo** di una bottiglia di vino sulla base di caratteristiche chimico-fisiche e qualitative.


Dataset

7.500
osservazioni · 11
variabili (rating,
num_reviews,
price, winery,
region, type...)

Ipotesi iniziali

Distribuzione del
prezzo
asimmetrica con
outlier; valori
mancanti e
incongruenze tra
variabili.

Analisi Esplorativa — Regressione



Qualità dei Dati

- 5.452 duplicati rimossi -> 2.048 osservazioni utili
- body & acidity: 15,6% valori mancanti

Statistiche Chiave

- rating: media 4,25 (std $\approx$ 0,12)
- price: mediana 28,53, max 3.119
- num_reviews: media 451, max 32.624

Correlazioni e Outlier

Correlazioni Numeriche

- **rating - price:** $r = 0,545$
(correlazione positiva moderata)
- **rating - num_reviews:** $r = 0,015$
(quasi nulla)
- **price - num_reviews:** $r = -0,030$ (trascurabile)

Correlazioni Categorie (V di Cramér)

- **wine - type:** $V = 0,990$
- **wine - region:** $V = 0,979$
- **winery - wine:** $V = 0,953$ -> forte ridondanza informativa

Outlier

Outlier evidenti in **price** (max 3.119,08 vs mediana 28,53) e **num_reviews** (max 32.624).
Decisione: mantenuti perché rappresentano entità reali del mercato.

Modelli Sviluppati — Regressione

Regressione Lineare & Ridge

Baseline interpretabile. Ridge aggiunge regolarizzazione L2 per penalizzare gli errori più grandi.

XGBoost

Gradient boosting su alberi decisionali. Ottimizzato per catturare relazioni non lineari complesse.

Rete Neurale

2 layer fully connected nascosti. Grid search su neuroni, learning rate, batch size e dropout.

Confronto delle Prestazioni — Regressione

Modello	MAE	RMSE	R ²	MSE	ADJ R ²
Linear Regression	72,8332	206,2976	0,2307	42558,70	0,2148
Ridge Regression	72,5280	205,3918	0,2374	42185,81	0,2216
XGBoost	56,9043	135,6596	0,6673	18403,52	0,6604
Neural Network	63,7248	172,7159	0,4607	29830,78	0,3603

📌 **XGBoost** ottiene le migliori prestazioni su tutte le metriche: MAE ridotto del 22% rispetto alla baseline lineare e R² di 0,67.

Interpretazione dei Risultati — Regressione

Regressione — Vincitore: XGBoost

$R^2 = 0,6673$ sul test set. I modelli lineari ($R^2 \approx 0,23$) confermano relazioni non lineari nei dati. Le reti neurali non superano XGBoost. Feature più importanti: **winery** e **rating**.



PROBLEMA B

Classificazione — Mice Protein Expression

Obiettivo

Classificare campioni di topi in base all'espressione proteica (genotipo, trattamento, comportamento).

Dataset


1.080 osservazioni · 82 variabili (77 proteine + 5 categoriche). 38 topi controllo, 34 trisomici.

Classi


8 classi bilanciate (9,72%–13,89% per classe). Valori mancanti in alcune proteine (fino al 26,39%).

Analisi Esplorativa — Classificazione


Distribuzione AcetylH3K9_N




Distribuzione APP_N




Distribuzione H3AcK18_N




Distribuzione class




Distribuzione pP70S6_N



Distribuzione SOD1_N



Distribuzione Tau_N



class

- ☐ c-CS-m
- ☐ c-CS-s
- ☐ c-SC-m
- ☐ c-SC-s
- ☐ t-CS-m
- ☐ t-CS-s
- ☐ t-SC-m
- ☐ t-SC-s

Analisi Esplorativa – Classificazione

Valori Mancanti

La maggior parte delle variabili ha solo lo 0,28% di dati mancanti.

Le proteine più critiche: BCL2_N (26,39%), H3MeK4_N (25,00%), BAD_N (19,72%).

Correlazioni

ARC_N - pS6_N: $r = 1,000$ (correlazione perfetta).

Numerose coppie con $r > 0,90$ (DYRK1A_N-BRAF_N, NR1_N-pNR1_N). Evidente ridondanza informativa.


Outlier & Duplicati

Outlier presenti in alcune feature (max ~7,04% dei campioni), ma mantenuti come variabilità biologica. **Nessun duplicato** rilevato nelle 1.080 osservazioni.

PCA — Riduzione Dimensionale

La **Principal Component Analysis (PCA)** trasforma le variabili originali (77 proteine) in componenti ortogonali che massimizzano la varianza spiegata, riducendo la dimensionalità. Per poterla visualizzare si porta a 2 componenti.

Sebbene vi sia una sovrapposizione parziale tra alcuni gruppi, si osserva che le diverse classi non sono distribuite in modo del tutto casuale, ma tendono a formare dei cluster distinti nello spazio proiettato.



Modelli Sviluppati — Classificazione

Regressione Logistica

Baseline probabilistico per classificazione binaria e multiclasse.

XGBoost

Gradient boosting su alberi decisionali. Ottimizzato per catturare relazioni non lineari complesse.

XGBoost + PCA

Variante con riduzione dimensionale tramite PCA prima del boosting.

Rete Neurale

2 layer fully connected nascosti. Grid search su neuroni, learning rate, batch size e dropout.

Confronto delle Prestazioni — Classificazione

Modello	Accuracy	F1-score	AUC	Precision	Recall
Reg. Logistica	0,9815	0,9817	0,9987	0,9823	0,9815
XGBoost Base	0,9861	0,9860	0,9998	0,9866	0,9861
XGBoost + PCA	0,9861	0,9863	0,9994	0,9863	0,9861
Rete Neurale	0,9907	0,9907	0,9992	0,9911	0,9907

📄 Cross-validation 5-fold (Rete Neurale): accuratezza media **0,9942**, std 0,0037.

Interpretazione dei Risultati — Classificazione

Classificazione — Vincitore: Rete Neurale

Accuracy 99,07%, ma miglioramento marginale rispetto a XGBoost (98,61%). Il dataset è quasi linearmente separabile. **XGBoost** rimane il miglior compromesso prestazioni/complessità.

99,07%

Rete Neurale

Accuracy — modello migliore

98,61%

XGBoost

Miglior compromesso complessità

Sviluppi Futuri

Hyperparameter Tuning

Ottimizzazione avanzata per trovare i parametri ottimali in modo efficiente.

Arricchimento Dataset

Aggiungere altre osservazioni ai dataset per migliorare le performance delle reti neurali.

Regressione

Ensemble Methods

Combinare XGBoost con altri modelli per migliorare ulteriormente R^2 e ridurre la varianza delle predizioni.

Classificazione

Confronto con Splitting per Gruppi

Raggruppamento delle osservazioni per tipo e splitting condizionato per valutazione più robusta.